



Tecnológico de Monterrey

ENTREGA 4

Paper Académico

Fernanda Vásquez A00837164

Luis Gerardo Juárez García A00836928

Julio César Madrigal John A01737106

Joseph Elí Pulido A01831526

Sergio David Laverde A01831525

Profesor Raúl Valente Ramírez Velarde

Concentración en Inteligencia Artificial (Gpo 101)

30 de noviembre del 2025

Índice

Índice.....	2
Abstract.....	2
Introducción.....	2
Marco Conceptual y Literatura.....	4
Datos y Contexto.....	6
Estrategia Empírica.....	8
Hallazgos Principales.....	10
Análisis de Mecanismos.....	13
Implicaciones Estratégicas.....	16
Conclusión.....	18
Referencias.....	18

Abstract

Este trabajo analiza los costos de flete de Ternium para identificar los determinantes estructurales del costo logístico por tonelada y estimar el potencial real de ahorro bajo políticas alternativas de asignación de rutas y transportistas. Nuestra pregunta central es: ¿cómo interactúan distancia, tiempo, peso, corredor y transportista en la formación del costo por tonelada, y cuánto podría reducirse dicho costo bajo escenarios contrafactuales realistas?

Metodológicamente combinamos modelos de machine learning explicable (Random Forest, Gradient Boosting, MLP) con un modelo econométrico OLS en logaritmos con efectos fijos por ruta y transportista ($R = 0.94$), análisis de series de tiempo ARIMA(1,1,1) por ruta y transportista, y simulaciones contrafactuales con bootstrap y Monte Carlo.

Los resultados muestran que distancia, tiempo y peso explican la mayor parte de la variación del $\text{Costo} \times \text{Tn}$. El tiempo influye como predictor clave, así como la distancia en modelos no lineales, aún sin ser parte explícita de la tarifa. Nos dimos cuenta que, rutas cortas como NL–Saltillo y corredores hacia Laredo aparecen entre 3 y 3.6 desviaciones estándar por encima de la media en costo normalizado por km/min, mientras que rutas como COA–AM Monterrey Local mantienen costos estables (235 MXN/Tn, CV = 5 %).

En los escenarios contrafactuales, homogeneizar la eficiencia al nivel del mejor transportista reduciría el costo promedio de 761 a 710 MXN/Tn (6–7 %). También, eliminar rutas extremas lo llevaría a 736 MXN/Tn (3–4 %); y una política de asignación que prioriza transportistas eficientes y rutas menos riesgosas lo reduce a 699 MXN/Tn (8–9 %) junto con una caída de 12 puntos en el índice de peligrosidad. Estratégicamente, los mayores retornos provienen de rediseñar reglas de asignación y benchmarking interno de rutas y proveedores, más que de cambios estructurales en la red logística.

Introducción

Intuitivamente, podemos pensar que “la distancia lo explica casi todo” en el costo de flete, sin embargo, nuestro análisis muestra algo diferente. Algunas de las rutas más cortas son precisamente las más caras una vez que normalizamos por kilómetro y minuto, y el tiempo de viaje termina pesando tanto como la distancia en los modelos no lineales. Estamos hablando de un costo promedio cercano a 761 MXN por tonelada y un rango robusto de 900–1,100 MXN/ton en escenarios de estrés, de modo que reducciones “pequeñas” de 6–9 % implican decenas de millones si se aplican a todo el volumen anual.

Sin embargo, los mecanismos que generan esta variabilidad no se dejan atrapar fácilmente por los enfoques tradicionales. Una tarifa basada casi exclusivamente en kilómetros recorridos ignora la fricción operativa capturada por el tiempo de tránsito, la eficiencia por tonelada y la heterogeneidad entre transportistas, que en nuestros modelos emergen como moduladores críticos del costo. Por otro lado, los modelos de ML explicable que usamos como punto de partida logran gran capacidad predictiva, pero ofrecen coeficientes poco interpretables y no permiten testar hipótesis causales de forma rigurosa. Añadimos un giro econométrico con efectos fijos corrige parcialmente esto, aunque sigue estando limitado por la ausencia de variables de contexto (riesgo real de ruta, incidentes, tarifas negociadas, tiempos de carga/descarga), lo que deja varias preguntas estructurales sin respuesta y representa una limitación/área de oportunidad en esta investigación.

¿Cómo interactúan distancia, tiempo, carga, corredor logístico y transportista para formar el costo por tonelada, y hasta qué punto un marco integrado de ML explicable, econometría con efectos fijos y series de tiempo puede separar mecanismos estructurales reales de artefactos de datos en el sistema logístico?

En este caso, proponemos y aplicamos un marco híbrido que combina modelos de ML (Random Forest, Gradient Boosting) con un modelo econométrico en logaritmos con efectos fijos por ruta y transportista, alcanzando un R^2 de 0.94 y proporcionando interpretaciones estructurales complementarias. Identificamos mecanismos causales plausibles donde la distancia fija la “base” del costo, el tiempo actúa como mediador operativo, el costo por tonelada modera la sensibilidad del sistema y el par origen destino encapsula heterogeneidad de corredor que no se explica por kilómetros ni tonelada únicamente. También, hicimos el espacio de mejora mediante estrategias como homogeneizar eficiencia de transportistas, recortar rutas extremas e introducir reglas de asignación costo-riesgo. Mostrando ahorros potenciales entre 3 % y 9 %.

Realizamos una clasificación crítica de hallazgos por robustez (robustos, medianamente robustos y frágiles), lo que permite distinguir resultados accionables, como el foco en rutas NL–Saltillo y Laredo o el rango de referencia 900–1,100 MXN/ton de conclusiones más frágiles, especialmente las asociadas al pricing por transportista y posibles cambios de régimen en diciembre.

Roadmap del paper

Primero describimos brevemente el dataset, las transformaciones iniciales y el enfoque base de ML explicable sobre el costo por tonelada. A continuación introducimos el modelo econométrico con efectos fijos y el bloque de series de tiempo a nivel ruta y transportista, comparando explícitamente lo que cada método revela y aquello que deja en la sombra. Después desarrollamos el análisis de

mecanismos causales y el estudio detallado por corredor, seguido de los ejercicios contrafactuales y de simulación que cuantifican el potencial de ahorro bajo políticas alternativas de asignación. En la sección posterior documentamos anomalías y outliers relevantes y realizamos pruebas de robustez y stress testing. Finalmente, cerramos con una reflexión crítica sobre las limitaciones de datos y métodos, las preguntas que siguen abiertas y las condiciones bajo las cuales las recomendaciones del paper deberían guiar decisiones reales de negocio.

Marco Conceptual y Literatura

Las siguientes tensiones son relevantes a nuestro problema:

Tensión 1: Costo logístico “unidimensional” vs estructura multidimensional y heterogénea

Buena parte de la modelación clásica del costo de transporte asume que éste puede representarse con funciones relativamente simples de distancia y, en menor medida, tiempo y peso. Existen especificaciones empíricas que corrigen por algunos factores adicionales, pero mantienen una estructura esencialmente aditiva y homogénea entre corredores. (Camisón-Haba, S., & Clemente-Almendros, J. A., 2019) En nuestros datos, confirmamos que distancia, tiempo y peso explican alrededor de 94 % de la variación de $\log(\text{Costo} \times \text{Tn})$ en un modelo OLS con efectos fijos por ruta y transportista, lo que respalda parcialmente esta visión.

Sin embargo, el análisis de ML explicable y de métricas normalizadas muestra que, el tiempo de viaje actúa como mediador, pues la misma distancia, diferencias en tiempo generan diferencias sustantivas en costo, asociadas a congestión, topografía y restricciones locales. Aplicamos indicadores como costo por tonelada, costo por km y costo por minuto revelan regímenes muy distintos entre corredores (rutas cortas pero caras, rutas largas económicas), difíciles de capturar con una función de costo promedio. Nos dimos cuenta de que la heterogeneidad de cada tramo, introduce patrones de costo que no se explican sólo por distancia o tonelada.

La primera tensión, entonces, es entre una teoría de costo dominante, y la evidencia empírica de un sistema donde fricciones operativas, geometría de corredor y normalizaciones por tonelada/tiempo alteran fuertemente la sensibilidad del costo.

Tensión 2: Modelos algorítmicos vs modelos estructurales.

Breiman describió la tensión entre la “cultura del modelo de datos” (econometría, modelos explícitos) y la “cultura algorítmica” (árboles, ensembles y otros modelos de ML), enfatizando que cada enfoque optimiza objetivos distintos: explicación estructural vs precisión predictiva. Por un lado, modelos como Random Forest y Gradient Boosting capturan no linealidades e interacciones complejas entre distancia, tiempo, peso, corredor y proveedor, y son los que alcanzan mejor desempeño predictivo global y mensual. (Chung and Kang, 2015; Shen et al., 2009)

Por otro lado, el modelo econométrico en logaritmos con efectos fijos por ruta y transportista, y variables temporales, proporciona elasticidades interpretables, permite pruebas de significancia y da una lectura estructural de los diferenciales de costo entre proveedores y corredores. Nos dimos cuenta de que los modelos algorítmicos ofrecen una representación muy fina del patrón de costos, pero son débiles para responder preguntas de tipo ¿cuánto aumenta el costo si el tiempo crece 10 % en esta

ruta?, mientras que el modelo estructural responde justo ese tipo de preguntas, pero a costa de imponer una forma funcional restrictiva que puede ignorar interacciones complejas.

Posicionamiento y gap conceptual

La literatura de costo y demanda de transporte ha desarrollado tanto modelos econométricos de demanda de flete como modelos de costo logístico que intentan especificar funciones de costo más realistas. Por otro lado, trabajos recientes han incorporado ML para modelar decisiones de modo o desempeño logístico, usando técnicas como CatBoost o Random Forest con interpretabilidad basada en SHAP para identificar los factores más influyentes. (Xu X, Yang H-C, Jeong K, Bui W, Ravulaparthi S, Laarabi H, Needell ZA and Spurlock CA, 2024)

Sin embargo, identificamos tres áreas de oportunidad donde podemos aportar

Integración sistemática de ML explicable, econometría con efectos fijos y series de tiempo sobre la misma base de microdatos de viajes, con el objetivo explícito de contrastar hallazgos y clasificar su robustez, pues la mayoría de estudios se queda en un solo tipo de modelo (por ejemplo, sólo econométrico o sólo ML) y rara vez discute cuándo un hallazgo es robusto, medianamente robusto o frágil en términos de sensibilidad a supuestos.

Así mismo, discutimos un enfoque en una industria concreta y su red de rutas y transportistas, en lugar de estudios agregados a nivel país o sector. La mayor parte de la literatura mide costos logísticos a nivel macro o usa datos muestrales agregados, mientras que aquí trabajamos con la totalidad de los viajes, lo que permite diseñar políticas de asignación e incentivos directamente accionables. (Karri Rantasila & Lauri Ojala, 2012)

En síntesis, posicionamos el paper como un aporte en la conversación sobre modelación de costos logísticos por medio del análisis de datos, pero con un énfasis poco frecuente en la triangulación metodológica entre ML, econometría y series de tiempo, y la traducción de esos resultados a reglas operativas específicas para una red logística real.

Framework conceptual propuesto

Proponemos un framework conceptual que estructura el costo logístico de Ternium en tres capas causales y analíticas:

Capa 1: Drivers estructurales

- Distancia (km)
- Peso total (ton)
- Ruta (Ori-Dest: tipo de ruta, infraestructura disponible)

Estos elementos definen la base física del costo: consumo mínimo de recursos, horas de conducción necesarias y capacidad requerida.

Capa 2: Fricciones operativas y riesgo

- Tiempo total de viaje (min/horas)
- Índice de peligrosidad de ruta (PeligroRuta)

- Volatilidad temporal por ruta/transportista

Esta capa explica por qué rutas con distancia similar pueden generar costos muy distintos, ya que, las fricciones operativas influyen en la complejidad del terreno, la regulación y la seguridad en sobre costos observados.

Capa 3: Arquitectura contractual y organizacional

- Transportista (Impacto-Transporte)
- Estructura de tarifas y condiciones particulares
- Volumen de rutas asignadas a cada proveedor

Se pueden observar diferencias sistemáticas entre empresas transportistas, que los modelos detectan como dummies de efectos fijos y como segundo feature más importante después de la distancia.

Resultado observable:

Costo por tonelada (CostoxTn) y sus métricas derivadas ($\text{Costo/ton}\cdot\text{km}$, $\text{Costo/ton}\cdot\text{min}$)

Volatilidad y regímenes temporales por ruta/transportista

Análisis de datos:

ML: Con las capas anteriores, podemos calcular un CostoxTn capaz de capturar no linealidades e interacciones complejas, y usa importancia de variables/SHAP para identificar drivers dominantes.

Econometría estructural: especifica un modelo en logaritmos con efectos fijos que estima elasticidades y diferenciales sistemáticos, dando una lectura causal disciplinada de cómo cambian los costos ante variaciones marginales en las capas definidas.


Time series: modelan la dinámica temporal de CostoxTn , detectan tendencias y posibles cambios de régimen y simulan escenarios no previstos.

Este framework hace explícito que el costo logístico no es sólo una función de kilómetros, sino el resultado de la interacción entre estructura física, fricciones operativas y arquitectura contractual, y que sólo puede entenderse de manera robusta cuando se triangulan estos niveles con métodos complementarios en lugar de elegir una única metodología de modelado.

Datos y Contexto

Para este reto, nuestro socio formador es Ternium, empresa que opera una red de transporte terrestre entre plantas y centros de distribución en México. (Ternium, n.d.). El objetivo del análisis son los viajes de transporte de material, donde el costo logístico se mide como costo por tonelada (CostoxTn) a nivel viaje y, en algunas secciones, agregado semanalmente por ruta o por transportista. Buscamos entender cómo varían estos costos entre rutas (origen–destino) y proveedores de transporte, más que describir todo el sistema logístico de Ternium.

El dataset que se nos compartió, está estructurado a nivel viaje. Nosotros comenzamos eliminando registros con valores faltantes en variables críticas (CostoxTn, distancia, tiempo y peso total) y generando variables de calendario a partir de la fecha de salida. El modelo econométrico alcanza un R de 0.94 sobre $\log(\text{CostoxTn})$, lo que indica que distancia, tiempo, peso y efectos fijos de ruta/transportista explican casi toda la variación del costo. Sin embargo, el costo por tonelada es muy disperso, tiene una media de 761 MXN/Tn, desviación estándar de 711 MXN/Tn y un rango de 87 a 13,492 MXN/Tn, lo que refleja la presencia de viajes y rutas extremas que dominan parte del comportamiento.



Existen rutas cortas muy costosas al normalizar el costo por km o por minuto, en particular NL-Salttillo y algunas rutas fronterizas (NL-Laredo, COA-Laredo), lo que sugiere que los costos fijos y los sobrecostos regulatorios en tramos aduaneros distorsionan la estructura tarifaria. Una fracción pequeña de rutas y transportistas se comporta como outliers, pero algunas concentran un volumen importante (ej. NL-Salttillo, siendo un 8.2 % de los viajes), de modo que decisiones sobre unos pocos corredores pueden tener efectos sistémicos en el costo promedio.

A nivel temporal, las series semanales de costo por tonelada muestran comportamientos heterogéneos, pues, hay rutas muy estables y baratas (ej. COA-AM Monterrey Local) y otras estructuralmente caras y volátiles (ej. rutas a SLP), con evidencia de tendencias o posibles cambios de régimen en algunas variables.

Limitaciones de los datos:

Consideramos que, una de las limitaciones que más se nos presentaron, fue la falta información clave de contexto operativo, ya que no se observan eventos externos (accidentes, bloqueos, huelgas), tiempos de carga/descarga, condiciones climáticas, ni el detalle de tarifas negociadas o paradas intermedias, que hubiera sido valioso conocer esa información. Además de complementar nuestros datos con variables relevantes como la peligrosidad real de la ruta. Pues, solo se incorporan parcialmente o como propuesta para trabajo futuro, lo que limita la identificación causal del efecto del riesgo sobre el costo.

Estrategia Empírica

Nuestro objetivo no solamente es predecir el costo, sino separar qué parte del costo logístico se explica por escala física del viaje (km, tiempo, tonelada) y qué parte se debe a características estructurales de ruta y transportista que sí pueden ser gestionadas o renegociadas.

Para acercarnos a esa separación, usamos tres ideas centrales:

1. Estandarizar el costo: además del $CostoxTn$, construimos métricas normalizadas (costo por tonelada·km y costo por tonelada·minuto) a partir de distancias y tiempos estimados en Google Maps para cada Ori-Dest. Esto nos permite distinguir rutas “caras porque son largas” de rutas “caras aun siendo cortas”.
2. Controlar por la ruta y el proveedor: al incluir efectos fijos por ruta (Ori-Dest) y por transportista, la variación que queda en el costo dentro de cada corredor/proveedor se interpreta como diferencias operativas.
3. Explorar la estructura no lineal con ML explicable: usamos modelos de machine learning (p. ej. Random Forest, Gradient Boosting, MLP) como forma flexible de aprender la función $f(distancia, tiempo, peso, ruta, transportista) = CostoxTn$, y luego descomponerla mediante importancias por permutación, PDPs y análisis de outliers para ver qué factores son predominantes en la práctica.

Primero limpiamos la parte del costo explicable por escala física, y sobre el residuo miramos si la heterogeneidad por corredor y transportista sigue siendo grande. Cuando una ruta o proveedor sigue quedando en la parte alta del ranking incluso después de normalizar y controlar efectos fijos, lo interpretamos como evidencia de ineficiencia relativa o condiciones contractuales especiales.

Nuestro socio tiene una pregunta muy concreta: “¿Dónde están las ineficiencias accionables en nuestro sistema de transporte?”, para responder esto, nos dimos cuenta que, un diseño de experimento natural no es viable, no hay cambio regulatorio que podamos explotar como variación.

Por otro lado, sí hay mucha variación temporal en distancia, tiempo, peso, rutas y proveedores, a nivel viaje. Esa es la variación que explotamos con modelos flexibles (ML) y modelos con efectos fijos (econometría) para descomponer el costo. Este enfoque es apropiado para nuestras preguntas porque, los modelos de ML capturan no linealidades e interacciones complejas y el modelo econométrico con efectos fijos proporciona elasticidades interpretables y permite comparar el peso relativo de distancia, tiempo y peso condicional a ruta y transportista. La estandarización de variables ($CostoxTnxkm$, $CostoxTnxmin$) y el análisis de outliers nos dan una vista al panorama del socio formador.

Ecuación principal e interpretación intuitiva

Aunque el proyecto se apoya en varios modelos, nuestra ecuación de referencia para el análisis estructural del costo es un modelo lineal en logaritmos con efectos fijos:

$$\log(CostoxTn_{irt}) = \beta_1 * \log(Distancia) + \beta_2 * \log(Tiempo) + \beta_3 * \log(Peso) + \alpha_r + \gamma_{prov} + \delta_t + \epsilon_{irt}$$


Este modelo no identifica la causalidad de un experimento natural, pero sí contribuye a la interpretación, cuando decimos que el tiempo es tan importante como la distancia, lo estamos afirmando condicionando a ruta y proveedor, no mezclando rutas largas con rutas cortas.

En paralelo, los modelos de ML complementan el análisis al permutar distancia, tiempo, peso, ruta y proveedor y medir cuánto crece el error (MAE), verificamos que el ranking de importancias coincide con la historia que cuenta el modelo lineal, ruta/transportista y los tres drivers físicos dominan la explicación del costo.

Estrategia de validación y robustez

- Validación cruzada temporal:

Se aplicó validación cruzada temporal con ventana creciente, reestimando el costo esperado por ruta con datos anteriores a la fecha de prueba. El error absoluto fuera de muestra se mantuvo acotado, lo que indica que el cálculo de costo por tonelada por ruta no depende de una sola partición de los datos.



Tests de robustez: ¿Los resultados se mantienen bajo diferentes especificaciones?

Ori-Dest	Costo por tonelada (MXN/Tn)	Costo por tonelada por km (MXN/Tn/km)	Costo por tonelada por minuto (MXN/Tn/min)	Posición por costo por tonelada	Posición por costo por tonelada por km	Posición por costo por tonelada por minuto
COA - Merida	3683.90	1.7103	2.2740	1	36	44
NL - Hermosillo	3396.12	2.2701	2.8928	2	13	20
COA - Mexicali	3306.74	1.6726	2.8630	3	39	23
NL - Chetumal	3294.81	1.6640	2.1965	4	40	47
NL - Tijuana	3262.37	1.3912	2.4094	5	52	40
NL - Mexicali	3150.28	1.4673	2.5243	6	49	35
NL - Tetla	2872.10	3.2091	4.2803	7	5	5
NL - Culiacan	2847.28	2.7404	3.9656	8	8	6

NL - San Pablo del Monte	2628.29	2.7961	3.5906	9	7	8
COA - Tijuana	2524.44	1.1607	2.0067	10	63	53

El análisis preliminar ya había generado tres métricas de costo para las mismas rutas (costo_x_tonelada_prom, costo_x_tonelada_prom_x_km, costo_x_tonelada_prom_x_min) a partir de la integración con la hoja de rutas. Esto permite contrastar si las rutas identificadas como más costosas siguen siéndolo cuando el costo se normaliza por distancia o por tiempo.

Como se aprecia en la Tabla 1, las rutas que aparecen en los primeros lugares cuando el costo se mide en costo por tonelada. Estas no necesariamente conservan esa posición cuando el costo se normaliza por kilómetro o por minuto. Los casos COA-Mérida, COA-Mexicali, NL-Chetumal, NL-Tijuana y COA-Tijuana ocupan los lugares 1 al 10 en la métrica principal, pero descienden hasta posiciones 36-63 cuando el costo se expresa por unidad de distancia o tiempo. Esto indica que buena parte de su costo elevado se explica por la longitud y duración del trayecto, no por una ineficiencia intrínseca de la ruta.

- Normalización y stress testing por ruta:

Comparamos rankings de rutas y proveedores usando simultáneamente, CostoxTn, CostoxTnxkm y CostoxTnxmin. Una ruta/proveedor sólo se considera realmente bajo observación si aparece en los primeros lugares en más de una métrica, si desaparece al normalizar, interpretamos su alto costo como efecto de escala, no de ineficiencia.

- Bootstrap por bloques temporales:

Aplicamos un bootstrap por bloques contiguos sobre la serie de viajes ordenada por fecha, con 500 réplicas. El intervalo de confianza al 95 % del costo promedio quedó estrecho (745-776 MXN/Tn alrededor de 760), lo que indica que nuestras estimaciones de nivel de costo son estables frente a la dependencia temporal del conjunto de datos.

Además, realizamos diagnósticos específicos de multicolinealidad en donde identificamos bloques correlacionados (distancia, tiempo y versiones normalizadas del costo). En especificaciones paramétricas incluimos solo una variable representativa (distancia o tiempo) para evitar inflar la varianza de los coeficientes. Para el análisis de casos extremos usamos percentiles y z-scores dentro de cada ruta para distinguir entre outliers explicables por distancia o tiempo y outliers que ameritan revisión operativa.


Hallazgos Principales

Hallazgo 1. Dispersión de costos

El primer resultado es que el sistema de fletes opera sobre una base fuertemente determinada por variables operativas, pero con una dispersión de costos elevada, que puede revelar ineficiencias estructurales. Como se mencionó anteriormente, el costo por tonelada oscila entre 87 y 13,492

MXN/Tn, con media cercana a 761 MXN/Tn y desviación estándar de 711 MXN/Tn, lo que implica un rango y una variabilidad muy altos entre rutas y transportistas. Esta dispersión ya se observa visualmente en el boxplot general de CostoxTn, donde la masa de observaciones se concentra en valores relativamente bajos mientras una cola larga de outliers empuja el rango máximo.

Los modelos de ML replican este diagnóstico, en la importancia por permutación, las variables más influyentes son la ruta (Ori-Dest), la distancia, el peso y el tiempo, y un heatmap de importancias por modelo muestra que, de manera robusta, distancia y tiempo dominan la explicación del costo, seguidos por las métricas normalizadas de costo por km y minuto.




Adicionalmente, se realizó el test de Breusch-Pagan para detectar heterocedasticidad y motivar el uso de errores robustos, lo que refuerza que las conclusiones no dependen de supuestos de varianza constante. La validación cruzada temporal confirma que los errores fuera de muestra se mantienen acotados, por lo que el patrón de determinantes no es un artefacto de una sola partición.

Hallazgo 2. El costo se concentra en pocas rutas y transportistas.

El segundo hallazgo es que las diferencias de costo no se distribuyen de manera uniforme, sino que se concentran en un subconjunto reducido de transportistas y rutas. A nivel proveedor, el análisis de outliers muestra que sólo unos cuantos transportistas concentran una proporción muy alta de viajes por encima del percentil 99 de costo por tonelada: NORTE CARGA GL (25%), SALVADOR SESATTY FLORES (19%) y RUBEN GERMÁN HERNÁNDEZ (16.7%). Esto sugiere que parte de los costos extremos responde a condiciones específicas de contratación o flota de estos actores, más que a ruido estadístico.

Las curvas de costo por tonelada de los principales transportistas refuerzan esta lectura: mientras firmas como TRASCARGA ESPECIALIZADA VILLARREAL operan con costos promedio cercanos a 250 MXN/Tn y volatilidad baja (4.6%), otros proveedores muestran niveles de costo significativamente mayores y perfiles de volatilidad de hasta 23–24%, alternando semanas muy caras con otras mucho más baratas. Esta combinación de nivel alto y variabilidad elevada implica riesgo presupuestal relevante para Ternium.



En el corte por rutas sucede algo similar. Trayectos largos o periféricos como NL-Chetumal, COA-Mérida, NL-Culiacán y NL-Hermosillo concentran las mayores proporciones de outliers de costo por tonelada, con proporciones de viajes extremos que llegan al 60% en algunos corredores. Sin embargo, cuando se normaliza por km y minuto se observa que no todos los corredores caros por tonelada son necesariamente ineficientes: algunos corresponden a rutas largas donde el alto costo refleja efectos estructurales de distancia y tiempo.

La implicación económica es que las oportunidades de ahorro no están distribuidas de forma uniforme, sino que se concentran en un puñado de proveedores y rutas, especialmente en tramos cortos donde los costos fijos y sobrecargos generan niveles de costo por tonne desproporcionados respecto a la distancia recorrida. Esto justifica estrategias de segmentación fina (por ruta-transportista) en lugar de políticas genéricas de reducción de tarifas.

Hallazgo 3. Políticas de asignación inteligentes permiten ahorros de 3-9% con trade-offs operativos y de riesgo

El tercer hallazgo muestra que rediseñar la política de asignación puede generar ahorros significativos en el costo promedio del sistema, pero con trade-offs claros entre viabilidad operativa y exposición al riesgo. En un primer escenario contrafactual, donde todos los transportistas operan con la eficiencia del mejor proveedor (por ejemplo, TRASCARGA ESPECIALIZADA VILLARREAL con CostoxTn 240-260 MXN/Tn), el costo promedio del sistema caería de 761 a aproximadamente 710 MXN/Tn, equivalente a un ahorro de 6-7%; este resultado se confirma mediante bootstrap con 500 réplicas.

Un segundo escenario elimina las rutas menos eficientes (percentil 95 de costo normalizado por km o minuto). En este caso el costo promedio se reduce a 736 MXN/Tn (3 a 4% de ahorro), pero la interpretación cualitativa señala que la eliminación de corredores largos o de alto riesgo puede ser operativamente inviable, ya que ciertas rutas representan hasta 8.22% del volumen de viajes y no tienen sustitutos evidentes.

El tercer escenario explora una política más realista: priorizar combinaciones de rutas y transportistas con costos por debajo de la mediana y menor índice de peligrosidad. Bajo esta regla, el costo promedio caería a 699 MXN/Tn, lo que supone ahorros de 8-9%, y simultáneamente el índice promedio de PeligroRuta se reduce en 12 puntos. Es decir, es posible diseñar una política que mejore tanto costo como riesgo, siempre que se asignen volúmenes suficientes a rutas y proveedores eficientes.

La implicación estratégica podría ser que Ternium use estos escenarios como benchmarks para diseñar contratos basados en métricas de desempeño (costo normalizado y riesgo), y más que eliminar rutas caras, el foco debería estar en renegociar condiciones en las rutas cortas y reorganizar el portafolio de transportistas, donde se concentra la mayor parte de la ineficiencia identificada.

Visión con modelos de Machine Learning (ML):

Se analizaron diferentes entrenamientos de modelos de aprendizaje automático para identificar las características más relevantes en la predicción de los costos de viaje. En los modelos de referencia, entrenados con las variables originales, el comportamiento fue consistente con la realidad operativa: la distancia fue consistentemente la variable con mayor influencia en la predicción de costos.

Sin embargo, al eliminar la distancia de la ecuación, el modelo redistribuyó su importancia y reveló que el impacto de las empresas transportistas también juega un papel significativo. Este hallazgo motivó un análisis más detallado por empresa de transporte, que identificó a "SALVADOR SESATTY FLORES" como uno de los factores predictivos más importantes. Esto no implica que esta empresa sea "mejor" o "peor", sino que su comportamiento estadístico es altamente consistente, lo que permite al modelo capturar patrones con mayor claridad. En otras palabras, esta empresa presenta datos con una estructura lo suficientemente estable como para ser utilizada como un punto de referencia robusto al evaluar modelos de forma más amplia.

Además, se realizó un estandarizado de las variables de costo, distancia y tiempo. Este ajuste arrojó un resultado interesante: al normalizar las magnitudes, el modelo redujo significativamente la importancia asignada a la distancia, mientras que los meses adquirieron mayor peso en la predicción. Esto sugiere la presencia de patrones temporales que podrían estudiarse con mayor precisión con un marco temporal más amplio, permitiendo una mejor comprensión de qué fenómenos estacionales o contextuales explican esta variación. Si se desea estudiar este efecto podría permitírnos datos de un año de viajes.

Análisis de Mecanismos

Nuestros resultados apuntan a tres mecanismos principales detrás de la variación del costo logístico:

- la escala física del viaje (distancia, tiempo y peso),
- las fricciones operativas de la ruta (velocidad efectiva, saturación, condiciones estructurales de la ruta)
- la arquitectura contractual y el riesgo (transportista y exposición a inseguridad).

A continuación mostramos cómo cada mecanismo opera, qué evidencia lo respalda y qué explicaciones alternativas pudimos descartar.

Mecanismo 1: la escala física del viaje

El primer mecanismo es casi mecánico: viajes más largos, más lentos o con menor carga efectiva tienden a ser más caros por tonelada. Al enriquecer los datos originales con distancia y tiempo estimados en Google Maps y derivar métricas normalizadas como `costo_x_tonelada_prom_x_km` y

costo_x_tonelada_prom_x_min, observamos que buena parte de los costos extremos se concentran en las rutas más largas.

En el análisis de outliers globales, 67 viajes (60.9%) de los valores extremos pertenecen a las 10 rutas más largas del conjunto, lo que es coherente con la hipótesis de escala, el costo es elevado porque la ruta es objetivamente más demandante en km y tiempo.

Cuando estandarizamos el costo dentro de cada corredor (z-scores por Ori-Dest), sólo tres rutas (NL-Tetla, NL-Culiacán, NL-San Pablo del Monte) permanecen en los primeros lugares aun después de ajustar por km y minuto, estas son las únicas que no se explican principalmente por escala y pasan a la categoría de casos especiales. En la síntesis de mecanismos, distancia provee la estructura base, tiempo actúa como mediador operativo y el costo por tonelada modera la sensibilidad del costo total a la carga transportada.

Mecanismo 2: fricciones operativas y condiciones estructurales de la ruta

El segundo mecanismo aparece cuando viajes de longitud moderada exhiben costos por tonelada por km/minuto desproporcionadamente altos. El indicador costo_x_tonelada_prom_x_min permite identificar la incidencia del tiempo como proxy de fricción operativa, valores altos se asocian con baja velocidad promedio o saturación en determinadas rutas.

En el ranking de rutas normalizadas, las rutas de NL-Área Metro Saltillo, COA-Laredo (TX), NL-Laredo (TX), NL-Arteaga y NL-Tetla aparecen como outliers aun después de controlar por distancia. La explicación propuesta es que son rutas muy cercanas al origen, donde el simple hecho de cargar, despachar y manejar trámites genera costos fijos que, en trayectos largos, se diluyen, pero en trayectos cortos dominan la estructura del costo.

El análisis realizado, indica que la estructura del costo no es homogénea entre las rutas, Ori-Dest captura que cada ruta combina condiciones que facilitan costos bajos (buena infraestructura, alta velocidad, baja densidad urbana) con condiciones que los elevan (zonas de riesgo, embotellamientos, carreteras inestables).

Podría argumentarse que estos costos altos se deben únicamente a transportistas ineficientes y no a la ruta. Sin embargo, al trabajar con métricas normalizadas por corredor (CostoxTnxkm, CostoxTnxmin) y comparar múltiples proveedores dentro de la misma ruta, vemos que el patrón de alto costo se mantiene en varias combinaciones, lo que sugiere que la ruta en sí misma es problemático, no sólo un proveedor específico.

Mecanismo 3: arquitectura contractual y exposición al riesgo

El tercer mecanismo está asociado a quién mueve la carga y por dónde, en términos de riesgo. Desde Entregas anteriores, se construyó el índice PeligroRuta (0–100), basado en tasas estatales de delitos, su objetivo es capturar de forma sintética la exposición del trayecto a la inseguridad.

Este índice permite separar ineficiencia pura de primas de riesgo justificadas, si dos rutas son operativamente similares pero PeligroRuta es mayor, parte del diferencial de costo puede atribuirse a seguros, escoltas, ventanas horarias más estrictas o riesgos operativos, en lugar de etiquetarlo como sobre costo injustificado.

El análisis de outliers por transportista muestra, que sólo un subconjunto de proveedores concentra la mayor proporción de viajes extremos (por ejemplo, NORTE CARGA GL con 25% de viajes outlier, SALVADOR SESATTY FLORES con 19%). Esto sugiere que, la arquitectura contractual y el perfil operativo de cada empresa de transporte (tarifas, tipo de flota, políticas de servicio) actúan como mecanismo adicional que amplifica o amortigua el efecto de la escala y de las fricciones del corredor.

La evidencia más clara de este mecanismo viene del Escenario 3 de análisis contrafactual, en el cual, al simular una política que penaliza transportistas con z-scores > 2 en costo y rutas con PeligroRuta > 70, el costo promedio se reduce de 761 a 699 MXN/Tn (ahorro de 8-9%) y el índice promedio de peligrosidad baja 12 puntos.

Es plausible que parte de las diferencias entre transportistas refleje servicios de mayor calidad (mayor cumplimiento, menor daño, tiempos garantizados) que no pudimos observar en los datos. No podemos descartar totalmente porque no contamos con indicadores de SLA ni de desempeño cualitativo. Esta es una de las razones por las que recomendamos interpretar los resultados como benchmarks de eficiencia relativa, no como juicios definitivos sobre la calidad global de cada proveedor.

Mecanismo 4: operacionalización vía dashboard de simulación what-if

Un hallazgo adicional de corte más instrumental es que los mecanismos anteriores pueden traducirse en una herramienta concreta de decisión, un dashboard interactivo de simulación what-if construido sobre el modelo estructural de costo

$$Costo \times Tn = f(\text{distancia, tiempo, PeligroRuta, transportista, tipo de transporte}).$$

Este dashboard permitiría a los analistas de Ternium explorar, en tiempo casi real, cómo cambian el costo esperado y el perfil de riesgo al modificar parámetros operativos clave:


- Flete / modalidad de transporte (plataforma, caja seca, full, etc.).
- Origen y destino (ruta Ori–Dest), asociado automáticamente a su índice PeligroRuta.
- Proveedor (transportista), con sus residuales históricos y métricas de eficiencia relativa.
- Escenario de política de asignación (benchmarking del mejor proveedor, eliminación de rutas extremas, reasignación penalizando alto costo y alto riesgo, etc.).

A partir de estos insumos, el dashboard devolvería:

- Costo proyectado por tonelada bajo el escenario seleccionado, comparado contra el nivel histórico (~761 MXN/Tn) y los escenarios contrafactuales (710, 736 y 699 MXN/Tn, equivalentes a ahorros de 3–9%).
- Índice de riesgo esperado de la ruta (PeligroRuta) y su variación relativa; por ejemplo, mostrar reducciones del orden de 10–12 puntos cuando se priorizan rutas de menor peligrosidad.
- Recomendaciones de asignación de rutas/proveedores.

En términos de mecanismo, el dashboard funciona como un puente entre la analítica y la operación: encapsula la lógica de los modelos (ML interpretable, regresión con efectos fijos y simulaciones Monte Carlo) y la expone en un lenguaje de negocio (“si cambio de proveedor en esta ruta, el costo

baja ~6–8% y el riesgo disminuye X puntos”). Esto no sólo facilita experimentar con los tres escenarios estudiados, sino que convierte el diseño de reglas de asignación en una palanca de gestión cotidiana, en lugar de un ejercicio aislado de análisis.



Implicaciones Estratégicas

Recomendación 1: Homogeneizar eficiencia al nivel del mejor transportista

Acción específica: Establecer un programa de benchmarking interno y renegociación de contratos para que todos los transportistas alcancen la eficiencia del mejor proveedor identificado.

Racionalidad: Basado en el hallazgo de que unos pocos transportistas concentran costos extremos y que homogeneizar la eficiencia reduce el costo promedio.

Impacto esperado: Reducción de 6–7 % en costos logísticos (IC 95 %: 5–8 %).

Riesgos: Posible resistencia de transportistas menos eficientes; riesgo de concentración excesiva en un solo proveedor.

Implementación:

- Construir un ranking de desempeño por transportista.
- Negociar cláusulas de eficiencia mínima.
- Diseñar incentivos de volumen para quienes alcancen benchmarks.

Recomendación 2: Rediseñar reglas de asignación costo-riesgo

Acción específica: Implementar un algoritmo de asignación que priorice rutas menos riesgosas y transportistas eficientes, podría hacerse igual con un dashboard para más simplicidad a la hora de usar.

Racionalidad: Basado en el hallazgo de que rutas cortas (NL-Salttillo, Laredo) son caras y riesgosas, y que una política de asignación costo-riesgo reduce costos y peligrosidad.

Impacto esperado: Reducción de 8–9 % en costos (IC 95 %: 7–10 %) y caída de 12 puntos en índice de peligrosidad.

Riesgos: Posible sobrecarga en rutas “seguras” y necesidad de renegociar contratos con transportistas.

Implementación:

- Definir métricas de peligrosidad y eficiencia.
- Ajustar sistema de asignación con reglas costo-riesgo.
- Pilotear en corredores críticos (NL-Salttillo, Laredo).

Recomendación 3: Eliminar o renegociar rutas extremas

Acción específica: Identificar rutas con costos extremos (ej. NL-Salttillo, COA-Laredo) y eliminarlas o renegociarlas con transportistas alternativos.

Racionalidad: Basado en el hallazgo de que unas pocas rutas concentran outliers de costo y que eliminarlas reduce el promedio.

Impacto esperado: Reducción de 3–4 % en costos (IC 95 %: 2–5 %)

Riesgos: Posible pérdida de cobertura logística en corredores estratégicos; necesidad de alternativas de transporte.

Implementación:

- Mapear rutas con z-score > 3 .
- Evaluar alternativas de proveedores o modos de transporte.
- Negociar contratos específicos para rutas críticas.

Recomendación 4: Normalización y monitoreo continuo

Acción específica: Implementar dashboards de costo normalizado (MXN/Tn·km y MXN/Tn·min) para monitorear eficiencia en tiempo real.

Racionalidad: Basado en el hallazgo de que rutas largas parecen caras por escala, pero al normalizar se distinguen ineficiencias reales.

Impacto esperado: Mejora en capacidad de detección temprana de ineficiencias; reducción indirecta de 2–3 % en costos por decisiones más informadas.

Riesgos: Requiere inversión inicial en sistemas de monitoreo y capacitación de personal.

Implementación:

- Integrar métricas normalizadas en dashboards internos.
- Entrenar equipos de logística en interpretación de métricas.
- Revisar rankings mensuales de rutas y transportistas.

Horizonte temporal y priorización

Corto plazo (0–6 meses): Normalización y monitoreo continuo; eliminación de rutas extremas.

Mediano plazo (6–12 meses): Homogeneizar eficiencia de transportistas mediante benchmarking y renegociación.

Largo plazo (12–24 meses): Rediseñar reglas de asignación costo-riesgo e integrarlas en sistemas de planeación logística.

Conclusión

Finalmente, logramos concluir que a lo largo del periodo, el principal aporte de este trabajo no es una cifra puntual de ahorro, sino una forma distinta de mirar el costo logístico. Empezamos con la idea de que la distancia lo explica todo y terminamos con un panorama mucho más matizado, ya que el costo por tonelada es el resultado de capas entrelazadas de física del viaje, fricciones de corredor y arquitectura contractual, que sólo se vuelven visibles cuando combinamos lentes metodológicos distintos. El reto mostró que la analítica no sólo sirve para ajustar tarifas o predecir facturas, sino para rediseñar reglas de juego dentro de una red logística concreta. Una contribución práctica central es que los mecanismos identificados pueden empaquetarse en un dashboard de simulación costo–riesgo, que convierte los modelos en una rutina de decisión cotidiana.

También quedan abiertas preguntas sobre la interacción entre analítica y gobernanza organizacional. Proponer dashboards y algoritmos de asignación no garantiza que se adopten ni que se sostengan en el tiempo. Futuras investigaciones podrían explorar cómo se integran este tipo de herramientas en los procesos de negociación con transportistas, en la planeación de demanda y en la gestión del riesgo operativo, así como los efectos en la distribución de poder entre áreas (finanzas, logística, compras, seguridad patrimonial). Entender esa dimensión política es clave si queremos que el modelo no se quede en un prototipo académico, sino que se convierta en parte de la decisión de la empresa.

Referencias

Chung and Kang, 2015; Shen et al., 2009. ECONOMETRIC MODELLING AND FORECASTING OF FREIGHT TRANSPORT DEMAND IN GREAT BRITAIN.

https://www.researchgate.net/publication/239551428_ECONOMETRIC_MODELLING_AND_FORECASTING_OF_FREIGHT_TRANSPORT_DEMAND_IN_GREAT_BRITAIN

Camisón-Haba, S., & Clemente-Almendros, J. A. (2019). A global model for the estimation of transport costs. *Economic Research-Ekonomska Istraživanja*, 33(1), 2075–2100.

<https://doi.org/10.1080/1331677X.2019.1584044>

Leo Breiman "Statistical Modeling: The Two Cultures (with comments and a rejoinder by the author)," *Statistical Science, Statist. Sci.* 16(3), 199-231, (August 2001)

<https://projecteuclid.org/journals/statistical-science/volume-16/issue-3/Statistical-Modeling--The-Two-Cultures-with-comments-and-a/10.1214/ss/1009213726.full>

Xu X, Yang H-C, Jeong K, Bui W, Ravulaparthi S, Laarabi H, Needell ZA and Spurlock CA (2024), Teaching freight mode choice models new tricks using interpretable machine learning methods.

<https://docs.nrel.gov/docs/fy24osti/88901.pdf>

Karri Rantasila* and Lauri Ojala. Measurement of National-Level Logistics Costs and Performance (2012).

https://www.oecd.org/content/dam/oecd/en/publications/reports/2012/05/measurement-of-national-level-logistics-costs-and-performance_g17a21d9/5k8zv79pzkk-en.pdf